

$\sqrt{2 \ln M_N}$ 경계선 구현 정리

notebooks/real_data_funnel.ipynb 6절 · 기준 커밋 eab07aa · 2026-09-30

한 줄 요약 — funnel에서 웨이퍼 수가 N 인 조합이 M_N 개 찍혀 있을 때, 그 평균들이 우연만으로 닿을 수 있는 폭을 $\sqrt{2 \ln M_N} \sigma_N$ 으로 잡고, 이보다 멀리 떨어진 조합을 경계 밖으로 표시합니다.

$$U(N), L(N) = \hat{\mu} \pm \sqrt{2 \ln M_N} \sigma_N, \quad \sigma_N = \frac{\hat{\sigma}}{\sqrt{N}} \sqrt{1 - \frac{N}{K}}$$

1. 입력 값

웨이퍼 $i = 1, \dots, K$ (root_lot_id + wafer_id)이고, good_bad가 G·B인 웨이퍼만 씁니다(N 은 계산에서 제외). 원래 Value v_i (y_value)를 아래 순서로 분석용 값 y_i 로 바꿉니다.

1. 방향: 클수록 좋은 값(HIGHER_IS_WORSE = False)이면 $v_i \leftarrow -v_i$.
2. 치우침: $|\text{skew}(v)| > 1$ 이면 순위 점수 $y_i = \Phi^{-1}\left(\frac{r_i - 0.5}{K}\right)$, r_i 는 v_i 의 순위(같으면 평균 순위).
3. part 보정: part 간 차이가 뚜렷하면($p < 0.001$ 이고 설명 비율 $\geq 1\%$) $y_i \leftarrow y_i - \bar{y}_{\text{part}(i)} + \bar{y}$.

$$\hat{\mu} = \frac{1}{K} \sum_{i=1}^K y_i, \quad \hat{\sigma} = \sqrt{\frac{1}{K-1} \sum_{i=1}^K (y_i - \hat{\mu})^2}$$

2. 점 = 조합

조합 c 는 한 STEP 안에서 Order $q_1, \dots, q_k$ ($k \leq \text{MAX_DEPTH}$)와 각 Order의 유닛 $u_1, \dots, u_k$ 를 고른 것입니다.

$$W_c = \{i : j = 1, \dots, k \text{ 모두에서 } A_i(q_j) = u_j\}, \quad N_c = |W_c| \geq N_{\min}, \quad \bar{y}_c = \frac{1}{N_c} \sum_{i \in W_c} y_i$$

$A_i(q)$ 는 웨이퍼 i 가 Order q 에서 지난 유닛이고, $N_{\min}$ 은 MIN_N (기본 20)입니다.

- 차트의 점 좌표는 $(x, y) = (N_c, \bar{y}_c)$ 입니다. 클수록 좋은 값이면 $-\bar{y}_c, -\hat{\mu}$ 로 그려 원래 부호로 보이게 합니다.
- Order 3개 이상 조합은 Order 하나를 뺀 조합 중 하나라도 결함 $z > 1.96\sigma$ 일 때만 계산하므로, 차트에 찍히는 점은 계산된 조합입니다. STEP을 지정하면 그 STEP의 조합만 찍습니다.

3. σ_N : 웨이퍼 N 장 평균이 우연히 벗어나는 폭

$$\sigma_N = \frac{\hat{\sigma}}{\sqrt{N}} \sqrt{\max\left(1 - \frac{N}{K}, \frac{1}{K}\right)}$$

근거: 웨이퍼 K 장에서 N 장을 비복원으로 뽑은 평균의 분산입니다. 모집단 분산을 $\sigma_{\text{pop}}^2 = \frac{K-1}{K} \hat{\sigma}^2$ 로 두면

$$\text{Var}(\bar{y}_N) = \frac{\sigma_{\text{pop}}^2}{N} \cdot \frac{K-N}{K-1} = \frac{\hat{\sigma}^2}{N} \left(1 - \frac{N}{K}\right)$$

- 레퍼런스 코드의 $\hat{\sigma}_n$ (n 장씩 m_n 번 뽑은 평균들의 표준편차)은 이 값을 뽑아서 추정한 것입니다. 실제형 가상 데이터에서 2,000번 뽑은 $\hat{\sigma}_n$ 과 식의 값의 비는 $N = 20, 50, 100, 300, 600$ 에서 0.99~1.01이었습니다.
- m_n 이 작으면 뽑아서 구한 값이 크게 흔들립니다($m_n = 2$: 0.04~1.87배, $m_n = 10$: 0.63~1.40배, 가운데 90%). 그래서 식으로 계산합니다.
- $\max(\cdot, 1/K)$ 는 N 이 K 에 가까울 때 폭이 0이 되지 않게 하는 하한입니다.

4. M_N 과 배수 $\sqrt{2 \ln M_N}$

$$M_N = \#\{c : N_c = N\}$$

같은 N 에 찍힌 점 수입니다. 레퍼런스처럼 N 마다 따로 세고, 전체 점 수를 합산하지 않습니다.

근거: $Z_1, \dots, Z_M \stackrel{iid}{\sim} \mathcal{N}(0, 1)$ 이면 최댓값은 M 이 클 때 $\sqrt{2 \ln M}$ 근처에 옵니다.

$$\mathbb{E} \left[\max_{j \leq M} Z_j \right] = \sqrt{2 \ln M} - \frac{\ln \ln M + \ln 4\pi}{2\sqrt{2 \ln M}} + o\left(\frac{1}{\sqrt{\ln M}}\right)$$

즉 $\sqrt{2 \ln M}$ 은 기대 최댓값보다 조금 큰 근사입니다. $M_N < 2$ 이면 $\hat{\sigma}_n$ 을 추정할 수 없어서(레퍼런스와 같음) 경계를 그리지 않고, 그 점은 판정하지 않습니다.

5. 경계와 판정

$$U(N) = \hat{\mu} + \sqrt{2 \ln M_N} \sigma_N, \quad L(N) = \hat{\mu} - \sqrt{2 \ln M_N} \sigma_N \quad (M_N \geq 2)$$

$$z_c = \frac{\bar{y}_c - \hat{\mu}}{\sigma_{N_c}}$$

나쁜 쪽 경계 밖: $M_{N_c} \geq 2$ 이고 $z_c > \sqrt{2 \ln M_{N_c}} \iff \bar{y}_c > U(N_c)$

좋은 쪽 경계 밖: $M_{N_c} \geq 2$ 이고 $z_c < -\sqrt{2 \ln M_{N_c}} \iff \bar{y}_c < L(N_c)$

이 판정은 비교용입니다. Value만 쓰고(bad 비율 미포함), 퍼짐 보정을 넣지 않은 레퍼런스 식 그대로입니다. 노트북의 실제 판정은 3절(결합 $z \cdot$ Bonferroni $\cdot$ 퍼짐 보정)입니다.

6. 예시 (실제형 가상 데이터)

$K = 1,130$, $\hat{\sigma} = 1.00$ (순위 점수), 조합 265,115개, $N = 20 \sim 644$, 서로 다른 N 560개.

N	M_N	$\sqrt{2 \ln M_N}$	σ_N	경계 폭 $\sqrt{2 \ln M_N} \sigma_N$	(참고) Bonferroni Order 1개 폭 $4.93 \sigma_N$
20	10,083	4.29	0.222	0.95	1.09
50	2,842	3.99	0.138	0.55	0.68
100	753	3.64	0.096	0.35	0.47
300	31	2.62	0.050	0.13	0.24

결과: 경계 밖 나쁜 쪽 149개, 좋은 쪽 87개, $M_N = 1$ 이라 경계가 없는 점 42개(N 42개).

7. 차트 표현

- 위 칸: 가로 $x = N$ (LOGX 면 로그 눈금), 세로 $y = \bar{y}_c$ (순위 점수로 바꿨으면 그 척도).
 - 파란 선: $U(N)$, $L(N)$. 점이 있는 N 마다 값이 정해지므로 계단 모양(steps-mid)이고, $M_N = 1$ 인 N 에서는 끊깁니다.
 - 점: 회색 = 경계 안 또는 판정 안 함, 빨강 = 나쁜 쪽 경계 밖, 진회색 = 좋은 쪽 경계 밖. 범례에 각 개수와 " $M_N = 1$ 이라 경계 없음" 개수를 적습니다.
- 아래 칸: N 마다 M_N (세로선, 로그 눈금).
- 세로 범위: 6절의 Bonferroni 차트들과 같게 잡습니다.

$$\text{span} = 1.05 \times \max \left(\max_c |\bar{y}_c - \hat{\mu}|, \max_k \left(\max_k z_k, \sqrt{2 \ln \max_N M_N} \right) \cdot \max_N \sigma_N \right), \quad y \in [\hat{\mu} - \text{span}, \hat{\mu} + \text{span}]$$




그림. 6절 $\sqrt{(2 \ln M_N)}$ 차트 (실제형 가상 데이터). 아래 칸은 N 마다의 점 수 M_N 입니다.

8. 지금 판정(Bonferroni)과의 차이

$$z_k = s \cdot \Phi^{-1} \left(1 - \frac{\alpha}{D M_k} \right), \quad \alpha = 0.05, \quad s = \max \left(1, \frac{\text{IQR}(z_c : k_c = 1)}{1.349} \right)$$

M_k = Order 수 k 에서 가능한 조합 수(계산을 건너뛴 조합 포함), D = 조합이 있는 Order 수, s = 퍼짐 배수입니다. Bonferroni는 차트 전체에서 우연히 하나라도 넘을 확률을 5%로 묶습니다. 반면 $\sqrt{2 \ln M_N}$ 은 N 마다 기대 최댓값 근처에 선을 긋기 때문에, 우연만으로도 N 마다 넘는 점이 생기고 서로 다른 N 이 많을수록 쌓입니다.

M	$\sqrt{2 \ln M}$	한 N 에서 우연히 넘을 확률 $1 - \Phi(\sqrt{2 \ln M})^M$	넘는 점 수 기댓값 $M(1 - \Phi(\sqrt{2 \ln M}))$
2	1.18	22.5%	0.24
10	2.15	14.8%	0.16
100	3.03	11.3%	0.12
1,000	3.72	9.6%	0.10
10,000	4.29	8.5%	0.09

한쪽(나쁜 쪽) 기준, 점들의 z 가 서로 독립인 표준정규라고 가정한 값입니다.

9. 코드 위치

- `shrink(n, N) =  $\sqrt{\max(1 - n/N, 1/N)}$  -  $\sigma_N$ 과 조합  $z$ 의  $\sqrt{1 - N/K}$  항`
- `envelope_points()` — 범위 안 조합의 $N_c, \bar{y}_c, z_c$, Order 수, M_{N_c}
- `plot_envelope('memo')` — 경계 · 판정 · 두 칸 차트 (계산 함수 셀), 6절 셀에서 호출