

$\sqrt{(2 \ln M_N)}$ 경계선 구현 정리

notebooks/real_data_funnel.ipynb 6절 · 웨이퍼 수별 퍼짐 $s(N)$ 튜닝 반영 · 2026-09-30

한 줄 요약 — funnel에서 웨이퍼 수가 N 인 조합이 M_N 개 찍혀 있을 때, 그 평균들이 우연만으로 닿을 수 있는 폭을 $\sqrt{2 \ln M_N} s(N) \sigma_N$ 으로 잡고, 이보다 멀리 떨어진 조합을 경계 밖으로 표시합니다. σ_N 은 무작위로 뽑은 평균의 폭 (레퍼런스), $s(N)$ 은 실제 조합이 그보다 몇 배 넓게 퍼졌는지(튜닝)입니다.

$$U(N), L(N) = \hat{\mu} \pm \sqrt{2 \ln M_N} s(N) \sigma_N, \quad \sigma_N = \frac{\hat{\sigma}}{\sqrt{N}} \sqrt{1 - \frac{N}{K}}$$

1. 입력 값

웨이퍼 $i = 1, \dots, K$ (`root_lot_id` + `wafer_id`)이고, `good_bad`가 G·B인 웨이퍼만 씁니다(N 은 계산에서 제외). 원래 Value v_i (`y_value`)를 아래 순서로 분석용 값 y_i 로 바꿉니다.

1. **방향**: 클수록 좋은 값(`HIGHER_IS_WORSE` = `False`)이면 $v_i \leftarrow -v_i$.
2. **치우침**: $|\text{skew}(v)| > 1$ 이면 순위 점수 $y_i = \Phi^{-1}\left(\frac{r_i - 0.5}{K}\right)$, r_i 는 v_i 의 순위(같으면 평균 순위). 왜도는 모든 part를 합친 값으로 잡니다.
3. **part 보정**: part 간 차이가 뚜렷하면($p < 0.001$ 이고 설명 비율 $\geq 1\%$) $y_i \leftarrow y_i - \bar{y}_{\text{part}(i)} + \bar{y}$

$$\hat{\mu} = \frac{1}{K} \sum_{i=1}^K y_i, \quad \hat{\sigma} = \sqrt{\frac{1}{K-1} \sum_{i=1}^K (y_i - \hat{\mu})^2}$$

2. 점 = 조합

조합 c 는 한 STEP 안에서 Order $q_1, \dots, q_k$ ($k \leq \text{MAX_DEPTH}$)와 각 Order의 유닛 $u_1, \dots, u_k$ 를 고른 것입니다.

$$W_c = \{i : j = 1, \dots, k \text{ 모두에서 } A_i(q_j) = u_j\}, \quad N_c = |W_c| \geq N_{\min}, \quad \bar{y}_c = \frac{1}{N_c} \sum_{i \in W_c} y_i$$

$A_i(q)$ 는 웨이퍼 i 가 Order q 에서 지난 유닛이고, $N_{\min}$ 은 `MIN_N` (기본 20)입니다.

- 차트의 점 좌표는 $(x, y) = (N_c, \bar{y}_c)$ 입니다. 클수록 좋은 값이면 $-\bar{y}_c, -\hat{\mu}$ 로 그려 원래 부호로 보이게 합니다.
- Order 3개 이상 조합은 Order 하나를 뺀 조합 중 하나라도 결합 $z > 1.96$ 일 때만 계산하므로, 차트에 찍히는 점은 계산된 조합입니다. STEP 을 지정하면 그 STEP의 조합만 찍습니다.

3. σ_N : 무작위로 뽑은 웨이퍼 N 장 평균의 폭 (레퍼런스)

$$\sigma_N = \frac{\hat{\sigma}}{\sqrt{N}} \sqrt{\max\left(1 - \frac{N}{K}, \frac{1}{K}\right)}$$

근거: 웨이퍼 K 장에서 N 장을 비복원으로 뽑은 평균의 분산을 $\sigma_{\text{pop}}^2 = \frac{K-1}{K} \hat{\sigma}^2$ 로 두면

$$\text{Var}(\bar{y}_N) = \frac{\sigma_{\text{pop}}^2}{N} \cdot \frac{K-N}{K-1} = \frac{\hat{\sigma}^2}{N} \left(1 - \frac{N}{K}\right)$$

- 레퍼런스 코드의 $\hat{\sigma}_n$ (n 장씩 m_n 번 뽑은 평균들의 표준편차)은 이 값을 뽑아서 추정한 것입니다. 실제형 가상 데이터에서 2,000번 뽑은 $\hat{\sigma}_n$ 과 식의 값의 비는 $N = 20, 50, 100, 300, 600$ 에서 0.99~1.01이었습니다.
- m_n 이 작으면 뽑아서 구한 값이 크게 흔들립니다($m_n = 2$: 0.04~1.87배, $m_n = 10$: 0.63~1.40배, 가운데 90%). 그래서 식으로 계산합니다.

4. $s(N)$: 실제 조합이 퍼진 만큼 폭 맞추기 (튜닝)

σ_N 은 웨이퍼를 무작위로 묶었을 때의 폭입니다. 실제 조합은 같은 랫 웨이퍼가 함께 움직이는 등의 이유로 이보다 넓게 퍼지고, 웨이퍼가 많을수록 더 퍼집니다. 실제 데이터 진단값(모든 점의 Value z 퍼짐)은 N 20~29: 1.54, 30~49: 1.69, 50~99: 1.98, 100~199: 2.11, 200~399: 3.31이었고, 레퍼런스 폭 그대로면 경계 밖이 10,283개였습니다. 그래서 N 별로 실제 퍼짐을 재서 곱합니다.

$$z_c^V = \frac{\bar{y}_c - \hat{\mu}}{\sigma_{N_c}}, \quad s(N) = \max\left(1, \frac{\text{IQR}\{z_c^V : k_c \leq 2, \frac{N}{1.25} \leq N_c \leq 1.25 N\}}{1.349}\right)$$

- $\text{IQR}/1.349$ 는 가운데 50% 폭으로 낸 표준편차라 튀는 불량 몇 개에 흔들리지 않습니다. 우연뿐이면 1입니다.
- Order 1~2개 조합만 씁니다. Order 3개 이상은 부모가 $z > 1.96$ 일 때만 계산해서 z 가 한쪽으로 치우쳐 있기 때문입니다.
- 범위 안의 점이 50개보다 적으면 범위를 1.25배씩 넓힙니다. N 의 로그 눈금으로 40개 점에서 재고, 그 사이는 선형 보간합니다.
- `SPREAD_ADJUST = False` 면 $s(N) = 1$ 이고, 레퍼런스 식 그대로입니다.

5. M_N 과 배수 $\sqrt{2 \ln M_N}$

$$M_N = \#\{c : N_c = N\}$$

같은 N 에 찍힌 점 수입니다. 레퍼런스처럼 N 마다 따로 세고, 전체 점 수를 합산하지 않습니다.

근거: $Z_1, \dots, Z_M \stackrel{iid}{\sim} \mathcal{N}(0, 1)$ 이면 최댓값은 M 이 클 때 $\sqrt{2 \ln M}$ 근처에 옵니다.

$$\mathbb{E}\left[\max_{j \leq M} Z_j\right] = \sqrt{2 \ln M} - \frac{\ln \ln M + \ln 4\pi}{2\sqrt{2 \ln M}} + o\left(\frac{1}{\sqrt{\ln M}}\right)$$

즉 $\sqrt{2 \ln M}$ 은 기대 최댓값보다 조금 큰 근사입니다. $M_N < 2$ 이면 $\hat{\sigma}_n$ 을 추정할 수 없어서(레퍼런스와 같음) 경계를 그리지 않고, 그 점은 판정하지 않습니다.

6. 경계와 판정

$$U(N) = \hat{\mu} + \sqrt{2 \ln M_N} s(N) \sigma_N, \quad L(N) = \hat{\mu} - \sqrt{2 \ln M_N} s(N) \sigma_N \quad (M_N \geq 2)$$

나쁜 쪽 경계 밖: $M_{N_c} \geq 2$ 이고 $z_c^V > s(N_c) \sqrt{2 \ln M_{N_c}} \iff \bar{y}_c > U(N_c)$

좋은 쪽 경계 밖: $M_{N_c} \geq 2$ 이고 $z_c^V < -s(N_c) \sqrt{2 \ln M_{N_c}} \iff \bar{y}_c < L(N_c)$

이 판정은 비교용입니다. Value만 씁니다(bad 비율 미포함). 노트북의 실제 판정은 3절(결합 z · Bonferroni · 웨이퍼 수별 퍼짐)입니다.

7. 예시 (실제형 가상 데이터)

$K = 1,130, \hat{\sigma} = 1.00$ (순위 점수), 조합 265,115개, $N = 20 \sim 644$, 서로 다른 N 560개. 이 데이터는 우연에 가깝게 만
든 것이라 $s(N)$ 이 대부분 1이고, 웨이퍼 500장 이상에서 1.38입니다.

N	M_N	$\sqrt{2 \ln M_N}$	$s(N)$	σ_N	경계 폭 $\sqrt{2 \ln M_N} s(N) \sigma_N$	(참고) Bonferroni Order 1개 폭
20	10,083	4.29	1.00	0.222	0.95	1.09
50	2,842	3.99	1.00	0.138	0.55	0.68
100	753	3.64	1.03	0.096	0.36	0.47
300	31	2.62	1.00	0.050	0.13	0.25

결과: 경계 밖 나쁜 쪽 104개, 좋은 쪽 60개, $M_N = 1$ 이라 경계가 없는 점 42개. 튜닝 전($s = 1$)은 149개 · 87개였습니다.

8. 차트 표현

- 위 칸: 가로 $x = N$ (LOGX 면 로그 눈금), 세로 $y = \bar{y}_c$ (순위 점수로 바꿨으면 그 척도).
 - 파란 선: $U(N), L(N)$. 점이 있는 N 마다 값이 정해지므로 계단 모양(steps-mid)이고, $M_N = 1$ 인 N 에서는 끊
깁니다. 범례: $\mu \pm \sqrt{2 \ln M_N} \cdot s(N) \cdot \sigma_N$.
 - 점: 회색 = 경계 안 또는 판정 안 함, 빨강 = 나쁜 쪽 경계 밖, 진회색 = 좋은 쪽 경계 밖. 범례에 각 개수와 " $M_N = 1$ 이
라 경계 없음" 개수를 적습니다.
- 아래 칸: N 마다 M_N (세로선, 로그 눈금).
- 세로 범위: 6절의 Bonferroni 차트들과 같게 잡습니다.

$$\text{span} = 1.05 \times \max \left(\max_c |\bar{y}_c - \hat{\mu}|, \max_N \left[\max_k \left(\max_k z_k s_B(N), \sqrt{2 \ln M_N} s(N) \right) \sigma_N \right] \right)$$




그림. 6절 $\sqrt{2 \ln M_N}$ 차트 (실제형 가상 데이터, $s(N)$ 튜닝 반영). 아래 칸은 N 마다의 점 수 M_N 입니다.

9. 지금 판정(Bonferroni)과의 차이

$$z_c^{\text{기준}} = s_B(N_c) \cdot \Phi^{-1} \left(1 - \frac{\alpha}{D M_{k_e}} \right), \quad \alpha = 0.05$$

M_k = Order 수 k 에서 가능한 조합 수(계산을 건너뛴 조합 포함), D = 조합이 있는 Order 수입니다. $s_B(N)$ 은 4절과 같은 방법으로 결합 z (Value + bad)의 퍼짐을 낸 것입니다. Bonferroni는 차트 전체에서 우연히 하나라도 넘을 확률을 5%로 묶습니다. 반면 $\sqrt{2 \ln M_N}$ 은 N 마다 기대 최댓값 근처에 선을 긋기 때문에, 우연만으로도 N 마다 넘는 점이 생기고 서로 다른 N 이 많을 수록 쌓입니다.

M	$\sqrt{2 \ln M}$	한 N 에서 우연히 넘을 확률 $1 - \Phi(\sqrt{2 \ln M})^M$	넘는 점 수 기댓값 $M(1 - \Phi(\sqrt{2 \ln M}))$
2	1.18	22.5%	0.24
10	2.15	14.8%	0.16
100	3.03	11.3%	0.12
1,000	3.72	9.6%	0.10
10,000	4.29	8.5%	0.09

한쪽(나쁜 쪽) 기준, 점들의 $z(s(N))$ 으로 나눈 값)가 서로 독립인 표준정규라고 가정한 값입니다.

10. 코드 위치

- `shrink(n, N)` = $\sqrt{\max(1 - n/N, 1/N)} - \sigma_N$ 과 조합 z 의 $\sqrt{1 - N/K}$ 항
- `spread_curve(combos, field)` — $s(N)$. `thresholds()` 가 결합 z 로 $s_B(\text{res['spread']})$, Value z 로 $s(\text{res['spread_value']})$ 를 만듭니다
- `envelope_points()` — 범위 안 조합의 $N_c, \bar{y}_c, z_c^V$, Order 수, 기준 z, M_{N_c}
- `plot_envelope('memo')` — 경계 · 판정 · 두 칸 차트 (계산 함수 셀), 6절 셀에서 호출